DOI: 10.7500/AEPS20250411004

基于大语言模型和深度强化学习联合决策的配电网重构方法

周茂一[1]，吴 志[1]，张 晓[1]，步冬冬[2]，孙振东[2]，赵瑞锋[3]
（1. 东南大学电气工程学院，江苏省南京市 210096；2. 深圳供电局有限公司，广东省深圳市 518001；
3. 广东电网有限责任公司广州供电局，广东省广州市 510623）

摘要：针对高比例新能源接入背景下配电网安全运行与负荷可靠供应的挑战，提出了一种基于大语言模型和深度强化学习智能体联合决策的配电网重构方法。首先，建立计及多目标优化的配电网动态重构模型，进一步设计了两阶段联合决策架构。第1阶段，微调大语言模型实现调度指令的意图识别与转供馈线范围的初步筛选，以辅助深度强化学习智能体的探索与学习；第2阶段，采用改进的SAC算法，通过Gumbel-Softmax重参数化技术确保策略网络可以从离散动作空间提取有效梯度信号，同时嵌入图卷积网络增强拓扑特征提取与变化感知能力。此外，为降低动作空间规模，引入“开关对”法和动作空间掩码机制，保证了所有操作合法性。最后，在某实际配电系统算例上验证了所提方法的有效性和优越性。

关键词：配电网重构；大语言模型；深度强化学习；智能体；SAC算法；图卷积网络；联合决策

0 引言

近年来，随着新型电力系统建设的推进，高比例可再生能源的规模化接入使得配电网运行环境日趋复杂[1-2]。分布式资源的广泛渗透在提升供电灵活性的同时，也加剧了配电网潮流的时空不确定性，导致传统辐射状配电网面临电压越限、网损增加、馈线过载等问题[3-4]。此外，经济的飞速发展导致负荷密度持续攀升，进一步放大了源荷时空错配引发的运行风险，对于电力可靠性和安全性的需求也日益增强[5]。在此背景下，配电网动态网络重构技术作为无须额外硬件投入的柔性调控手段，可以通过优化网络拓扑结构实现潮流再分布，成为提升配电网运行经济性与安全性的关键技术路径[6-7]。

目前，配电网动态网络重构传统研究方法主要基于数学优化模型描述网络拓扑约束，采用确定性或启发式算法求解最优或次优重构方案。文献[8]提出分级自治重构策略，通过主配协同孤岛划分提升故障恢复鲁棒性。文献[9]在改进布谷鸟算法中引入电压可靠性与线路负载率约束，显著提升实时负荷转供效率。文献[10]通过融合莱维系数量子粒子群算法与拓扑特性，有效克服分布式电源接入导致的局部收敛问题。文献[11-12]将电力市场机制与重构模型耦合，挖掘网荷双侧协同优化潜力。文献[13]采用基于新型元启发式算法的智能框架，通过智能空间压缩与解精修机制，显著提升了重构控制效果。然而，随着配电网重构规模的扩大，传统方法面临计算复杂度呈指数增长的问题，而基于人工智能的智能重构方法因其并行决策优势，在求解效率方面展现出显著竞争力。

深度强化学习（deep reinforcement learning，DRL）凭借其智能体与环境的自主交互学习能力，可有效解决配电网重构中的高维离散动作空间优化问题。现有研究已在算法架构设计方面取得一定进展。文献[2]通过量化开关贡献度构建两阶段奖励共享机制，实现关键开关的优先调控。文献[14]提出数据驱动批量约束算法，基于历史数据离线学习具备实时扩展性的重构策略。文献[15]采用状态序列化建模与近似动态规划相结合的方法，有效应对维度灾难挑战。文献[16]提出了双图神经网络框架，实现拓扑重构与电压无功的协同优化。文献[17]基于多智能体SAC（soft actor-critic）算法构建微网形成机制，提升了极端事件下的关键负荷恢复能力。文献[18]则通过DRL辅助多目标优化，高效求解重构问题的帕累托前沿。

然而，现有研究大多聚焦于算法层面的优化，且优化角度多集中于决策空间的数学建模与求解算法

收稿日期：2025-04-11；修回日期：2025-07-25。
上网日期：2025-09-02。
智能电网国家科技重大专项资助项目（2024ZD0802200）。

的改进。这种研究路径仍存在以下不足：1)主流算法普遍采用海量决策空间内的暴力搜索策略，缺乏基于调度意图识别的启发式探索机制；2)现有方法通常将指令解析和网络重构作为两个独立环节进行处理，未能实现从调度语义到控制策略的有机融合；3)由于缺乏有效的自然语言处理技术支持，调度人员基于运行经验提出的非结构化指令难以与算法优化决策形成闭环协同。以上技术瓶颈制约了配电网重构模型在复杂运行环境下的自适应调控能力。

近年来，大语言模型(large language model，LLM)技术的快速发展为电力系统调度指令的智能解析提供了新的技术路径。文献[19]系统论证了LLM在电力调度领域的应用潜力，并指出该技术在实际工程应用中仍需解决领域知识嵌入、物理约束融合和实时性提升等问题。在调度意图识别方面，文献[20]基于ALBERT和RE2的融合模型，通过动态词向量表征与文本相似度计算的协同优化，实现了对20类标准化调度指令98%以上的识别准确率。然而，该文研究主要针对的是结构化调度文本的语义映射，在处理包含隐含需求、非标准化、非结构化的调度意图(如调度员发出的指令为“改善馈线1末端节点电压”)时，依然存在局限性。

因此，本文提出了一种融合微调LLM与DRL的配电网动态重构框架。首先，建立动态重构的多目标数学模型。其次，设计两阶段决策架构：第1阶段通过自适应微调的LLM实现调度指令语义解析与馈线转供预筛选；第2阶段采用改进的SAC算法，其中嵌入图卷积网络(graph convolutional network，GCN)以增强拓扑特征提取能力，并引入“开关对”法和动作空间掩码机制以降低决策维度。最后，通过算例仿真验证了所提方法的有效性。

1　配电网重构模型

本文提出的配电网动态重构框架如图1所示。

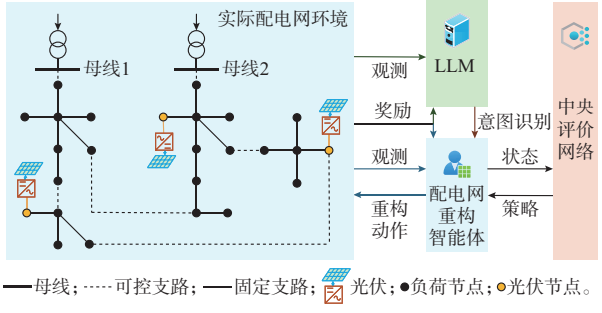


图1　配电网动态重构框架

Fig. 1　Dynamic reconfiguration framework of distribution network

随着高比例可再生能源(如光伏发电)在配电网中的渗透率持续提升，配电网重构技术在优化网络运行方面的关键作用日益凸显。图1中，配电网重构智能体负责调控网络中的所有可控支路，通过智能化的开关操作实现配电网拓扑结构的动态优化。

在观测系统设计方面，LLM与DRL智能体均实时采集本地拓扑数据及节点物理量测信息，进而构建完整的观测空间。特别地，本框架创新性地引入LLM技术，其首先基于电力业务需求进行深层次的意图识别与解析，初步筛选需要进行转供的馈线范围，进而为智能体的策略选择提供决策辅助。

在集中优化机制方面，云端部署的中央评价网络旨在构建全局状态空间与价值评估体系。基于全局奖励信号与智能体的策略分布，中央评价网络同步计算自身与智能体网络的梯度更新方向，并完成网络参数更新。值得注意的是，奖励值将同时实时反馈至LLM，为其参数微调提供数据支撑，从而形成闭环并行优化系统。

1.1　电压控制设备建模

对于配电网中的无功电压控制设备，本文主要针对光伏进行建模。式(1)为光伏出力的上下限约束；式(2)计算了t时刻的弃光量；式(3)为弃光率上限约束；式(4)为容量约束[21]。

$$0 \leqslant P_t^{\mathrm{PV}} \leqslant P_{\max,t}^{\mathrm{PV}} \tag{1}$$

$$P_{\mathrm{cut},t}^{\mathrm{PV}} = P_{\max,t}^{\mathrm{PV}} - P_t^{\mathrm{PV}} \tag{2}$$

$$P_{\mathrm{cut},t}^{\mathrm{PV}} \leqslant \kappa_{\max}^{\mathrm{PV}} P_{\max,t}^{\mathrm{PV}} \tag{3}$$

$$\sqrt{(P_t^{\mathrm{PV}})^2 + (Q_t^{\mathrm{PV}})^2} \leqslant S^{\mathrm{PV}} \tag{4}$$

式中：$P_{\max,t}^{\mathrm{PV}}$为t时刻光伏的最大出力；P_t^{PV}为t时刻光伏的实际出力；Q_t^{PV}为t时刻光伏系统吸收或发出的无功功率；$P_{\mathrm{cut},t}^{\mathrm{PV}}$为$t$时刻弃光有功功率；$\kappa_{\max}^{\mathrm{PV}}$为弃光率上限；$S^{\mathrm{PV}}$为光伏的容量。

1.2　配电网辐射状约束

由于继电保护的要求，配电网应保持辐射结构，这也是配电网重构时必须遵守的约束之一。配电网中联络开关的开关组合需要满足辐射状约束[22]，具体来说需要满足以下2个条件：1)基本回路中至少有一个分支应断开，以避免出现回路；2)2个基本回路的公共分支中不允许有一个以上的分支关闭，以避免出现孤岛。上述2个条件的公式表达如下：

$$\mu_{ij,t}^{\mathrm{TS}} \in \{0,1\} \qquad \forall ij \in \Omega_{\mathrm{TS}} \tag{5}$$

$$n_{\mathrm{Z}} - (n_{\mathrm{J}} - n_{\mathrm{B}}) = \sum (1 - \mu_{ij,t}^{\mathrm{TS}}) \qquad \forall ij \in \Omega_{\mathrm{TS}} \tag{6}$$

$$i \in f_{\mathrm{DFS}}(j) \qquad \forall i \in \Omega_{\mathrm{Bus}}, \exists j \in \Omega_{\mathrm{Sub}} \tag{7}$$

式中：t为时间索引；ij为节点i与节点j之间的支路的索引；Ω_{TS}为配备联络开关(tie switch，TS)的支路

的集合；Ω_{Sub}为配电网馈线根节点的集合；Ω_{Bus}为节点的集合；n_{Z}、n_{J}、n_{B}分别为支路、节点、馈线根节点的数量；$\mu_{ij,t}^{\mathrm{TS}}$为一系列0-1变量，表示t时刻TS的开关状态，本文设定$\mu_{ij,t}^{\mathrm{TS}}$取0值表示TS断开，反之取1表示TS闭合；$f_{\mathrm{DFS}}(\cdot)$为从根节点出发，利用深度优先搜索(depth first search，DFS)算法遍历得到的节点集合。本文中称配备TS的支路为可控支路，反之称为固定支路。

式(7)保证了条件2的满足。联立式(5)至式(7)可以保证配电网不存在回路，即保证了条件1的满足。

1.3　配电网潮流约束

式(8)采用二阶锥松弛，将非线性约束凸松弛化[23]。式(11)表示ij支路配备TS时，$\mu_{ij,t}^{\mathrm{BR}}$等于$\mu_{ij,t}^{\mathrm{TS}}$，支路ij无TS时，$\mu_{ij,t}^{\mathrm{BR}}$等于1表示恒为闭合。式(12)、式(13)使用大M法，保证了TS打开时，该TS所在支路的两端节点电压不互相影响。式(14)和式(15)分别是电压上下限和传输电流上限约束。式(16)为根节点注入的有功功率上下限约束；式(17)为根节点注入的无功功率上下限约束[24]。

$$U_{i,t}^2 I_{ij,t}^2 \geqslant P_{ij,t}^2 + Q_{ij,t}^2 \tag{8}$$

$$\sum_{i\in\Omega_m(j)}(P_{ij,t}-r_{ij}I_{ij,t}^2)=\sum_{k\in\Omega_n(j)}P_{jk,t}+P_{j,t}^{\mathrm{load}}-P_{j,t}^{\mathrm{PV}} \tag{9}$$

$$\sum_{i\in\Omega_m(j)}(Q_{ij,t}-x_{ij}I_{ij,t}^2)=\sum_{k\in\Omega_n(j)}Q_{jk,t}+Q_{j,t}^{\mathrm{load}}-Q_{j,t}^{\mathrm{PV}} \tag{10}$$

$$\mu_{ij,t}^{\mathrm{BR}}=\begin{cases}\mu_{ij,t}^{\mathrm{TS}} & \forall ij\in\Omega_{\mathrm{TS}}\\ 1 & \text{其他}\end{cases} \tag{11}$$

$$U_{j,t}^2-U_{i,t}^2\leqslant M(1-\mu_{ij,t}^{\mathrm{BR}})-2(r_{ij}P_{ij,t}+x_{ij}Q_{ij,t})+[r_{ij}^2+x_{ij}^2]I_{ij,t}^2 \tag{12}$$

$$U_{j,t}^2-U_{i,t}^2\geqslant -M(1-\mu_{ij,t}^{\mathrm{BR}})-2(r_{ij}P_{ij,t}+x_{ij}Q_{ij,t})+(r_{ij}^2+x_{ij}^2)I_{ij,t}^2 \tag{13}$$

$$U_{j,\min}\leqslant U_{j,t}\leqslant U_{j,\max} \tag{14}$$

$$I_{ij,t}\leqslant\mu_{ij,t}^{\mathrm{BR}}I_{ij,\max} \tag{15}$$

$$P_{\min}^{\mathrm{root}}\leqslant P_{j,t}\leqslant P_{\max}^{\mathrm{root}}\qquad\forall j\in\Omega_{\mathrm{Sub}} \tag{16}$$

$$Q_{\min}^{\mathrm{root}}\leqslant Q_{j,t}\leqslant Q_{\max}^{\mathrm{root}}\qquad\forall j\in\Omega_{\mathrm{Sub}} \tag{17}$$

式中：$\Omega_m(j)$为配电网中以j为末端节点的支路的首端节点集合；$\Omega_n(j)$为配电网中以j为首端节点的支路的末端节点集合；$U_{j,t}$为t时刻j节点的电压幅值；$P_{ij,t}$和$Q_{ij,t}$分别为t时刻支路ij首端的有功功率和无功功率；$P_{j,t}^{\mathrm{load}}$和$Q_{j,t}^{\mathrm{load}}$分别为t时刻负荷有功功率、负荷无功功率；r_{ij}和x_{ij}分别为支路电阻和电抗；M为一个较大的值；$U_{j,\max}$和$U_{j,\min}$分别为节点j电压的上、下限值；$I_{ij,\max}$为线路ij的电流上限值；$I_{ij,t}$为流过支路ij的电流；$\mu_{ij,t}^{\mathrm{BR}}$表示支路ij的开关状态；$P_{\max}^{\mathrm{root}}$和$P_{\min}^{\mathrm{root}}$分别为从根节点流入配电网的有功功率上、下限；$Q_{\max}^{\mathrm{root}}$和$Q_{\min}^{\mathrm{root}}$分别为从根节点流入配电网的无功功率上、下限；$P_{j,t}$和$Q_{j,t}$分别为从根节点流入配电网的有功功率和无功功率，$\forall j\in\Omega_{\mathrm{Sub}}$。

1.4　目标函数

文献[25]表明配电网重构的目标是通过改变网络拓扑来降低网损、减少电压偏差、提高馈线负荷均衡性。因此，构造目标函数式(18)并给予不同的权重以综合考虑(展开式的4项分别对应4种指标)。

$$\min\sum_{t=1}^{T}\Bigg[\underbrace{c_1\sum_{i=1}^{n_{\mathrm{J}}}(U_{i,t}-1)^2}_{\text{电压偏差}}+\underbrace{c_2\sum_{i=1}^{n_{\mathrm{J}}}\sum_{j\in\Omega_n(i)}I_{ij,t}^2r_{ij}\Delta t}_{\text{网损}}+\underbrace{c_3\sum_{ij\in\Omega_{\mathrm{TS}}}|\mu_{ij,t+1}^{\mathrm{TS}}-\mu_{ij,t}^{\mathrm{TS}}|}_{\text{TS动作成本}}+\underbrace{c_4\sum_{i\in\Omega_{\mathrm{Sub}}}(P_{i,t}-\bar{P}_t)^2}_{\text{馈线负荷均衡性}}\Bigg] \tag{18}$$

式中：T为周期总时间步长；$\bar{P}_t$为流过所有馈线功率的平均值；c_1、c_2、c_3和c_4为权重系数；Δt为时间间隔。

2　LLM与DRL智能体的联合两阶段决策

如图2所示，本文提出了一种融合LLM和DRL智能体的两阶段决策框架。

在第1阶段，LLM基于电网运行状态生成候选馈线编号；第2阶段则基于所选馈线，由DRL智能体确定具体的开关对操作，并实时同步反馈奖励值。两个阶段通过联合参数训练实现并行优化，构建互为监督的协同机制。其中，DRL生成的奖励值被引入作为LLM损失函数的关键输入；LLM输出的馈线编号也反过来影响了奖励的生成过程。

为增强模型对电网拓扑变化的感知能力，在DRL智能体中嵌入了GCN。本文提出的框架有效结合了LLM的语义理解能力和DRL的优化决策优势，为配电网重构提供了一种新的解决方案。详细的原理分析见2.1节和2.2节。

2.1　基于大模型的第1阶段决策

本文对于LLM微调的过程中，首先基于低秩自适应(low-rank adaptation，LoRA)微调对预训练模型进行初步的监督微调阶段，再进一步借助群体相对策略优化(group relative policy optimization，GRPO)强化学习方法对模型进行优化。

首先，相较于全参微调，LoRA微调借助低秩分解技术，仅需训练极少量参数即可获得逼近全参微调的性能，显著降低了计算成本[26]。

根据奇异值分解的概念，可以将一个非零$m\times n$的实数矩阵$\boldsymbol{\xi}\in\mathbf{R}^{m\times n}$近似分解为以下3个实数矩阵

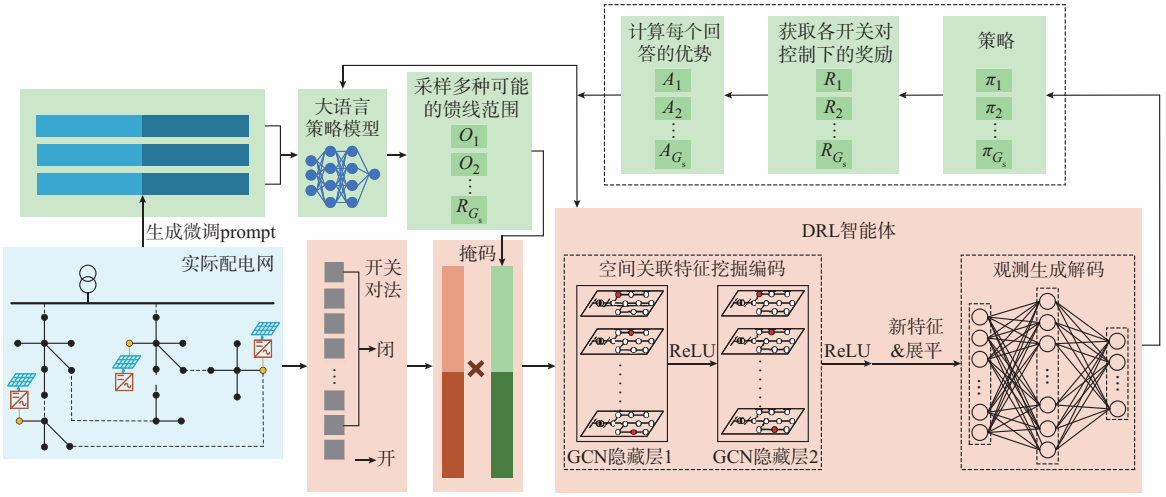


图2　基于LLM与DRL智能体的联合两阶段决策框架

Fig. 2　Joint two-stage decision-making framework based on LLM and DRL agent

相乘并保留了最大的k个奇异值，其中，$k \ll r_z$，r_z为$\boldsymbol{\xi}$的秩。

$$\boldsymbol{\xi} \approx \boldsymbol{C\Xi\zeta}^{\mathrm{T}} \tag{19}$$

式中：$\boldsymbol{C}$为$m \times r_z$的实数矩阵；$\boldsymbol{\zeta}$为$n \times r_z$的实数矩阵；$\boldsymbol{\Xi}$为$r_z \times r_z$的实对角矩阵。

由式(19)可知，原矩阵可以由低秩矩阵近似表示。具体来说，对于LoRA微调，将$\boldsymbol{C\Xi}$的乘积合并为待学习的矩阵$B_1 \in \mathbf{R}^{m \times r_z}$，将$\boldsymbol{\zeta}^{\mathrm{T}}$表示为待学习的矩阵$B_2 \in \mathbf{R}^{r_z \times n}$，有

$$\boldsymbol{h}_{\mathrm{out}} = \boldsymbol{\varpi x}_{\mathrm{in}} + \Delta\boldsymbol{\varpi x}_{\mathrm{in}} \approx \boldsymbol{\varpi x}_{\mathrm{in}} + B_1 B_2 \boldsymbol{x}_{\mathrm{in}} \tag{20}$$

式中：$\boldsymbol{h}_{\mathrm{out}}$为模型的输出；$\boldsymbol{x}_{\mathrm{in}}$为模型的输入；$\Delta\boldsymbol{\varpi} \in \mathbf{R}^{m \times n}$为参数增量矩阵；$\boldsymbol{\varpi}$为参数矩阵。$B_1$需初始化为零矩阵；$B_2$需初始化为正态分布。

其次，传统的LLM微调通常在该阶段选择近端策略优化(proximal policy optimization，PPO)算法。然而，PPO算法存在两大缺陷：1)其值函数通常需要构建与策略(actor)模型规模相当的神经网络模型，这显著增加了内存占用和计算成本；2)在LLM的训练场景中，值函数被用作优势估计的基准线，但由于奖励模型通常仅对生成序列的最终词元(token)赋予奖励信号，这种稀疏奖励特性使得值函数的训练过程面临严重的信用分配问题，进而导致价值估计的偏差和方差增大。针对上述问题，本文参考DeepSeek的技术路线[27]，采用GRPO算法优化微调LLM。

为方便下文表述，定义策略概率比为R_{pp}：

$$R_{\mathrm{pp}} = \frac{\pi_\theta(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\mathrm{old}}}(o_{i,t} \mid q, o_{i,<t})} \tag{21}$$

式中：θ为新策略参数；θ_{old}为旧策略参数；q为输入查询，本文中指输入LLM的提示(prompt)，本文所需的prompt分为系统prompt和用户prompt，具体的设计方法会在算例中展示；对于每个输入查询q，GRPO法从旧策略$\pi_{\theta_{\mathrm{old}}}$中采样输出序列组$\{o_1, o_2, \cdots, o_{G_s}\}$，共$G_s$个独立采样序列，利用语言处理技术进一步将$\{o_1, o_2, \cdots, o_{G_s}\}$提取为$G_s$组待转供的馈线编号组；$o_{i,t}$和$o_{i,<t}$分别为当前选择的输出序列和历史输出序列。

式(22)的分子和分母分别表示新策略π_θ和旧策略$\pi_{\theta_{\mathrm{old}}}$在给定$q$和历史$o_{i,<t}$下，生成输出序列$o_{i,t}$的概率分布。$R_{\mathrm{pp}}$衡量了新策略相对于旧策略对同一动作的偏好变化程度。

策略网络可以通过最大化下述目标函数来进行优化：

$$J_G(\theta) = E\left[q, \{o_i\}_{i=1}^{G_s} \sim \pi_{\theta_{\mathrm{old}}}(O \mid q)\right] \cdot \frac{1}{G_s}\sum_{i=1}^{G_s}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\left[\min\left[R_{\mathrm{pp}}, \mathrm{clip}(R_{\mathrm{pp}}, 1-\varsigma, 1+\varsigma)\right]\hat{A}_{i,t}\right] \tag{22}$$

式中：$|o_i|$为第i个输出序列的长度，本文指生成文本的词元数；O为o_i的集合；clip(·，$1-\varsigma$，$1+\varsigma$)表示将R_{pp}限制在$[1-\varsigma, 1+\varsigma]$内，旨在防止策略突变；$\varsigma$为有关剪切机制的参数；$\hat{A}_{i,t}$为$o_{i,t}$的优势函数，其计算方式见下文。

给定q和G_s个采样输出$\{o_1, o_2, \cdots, o_{G_s}\}$，定义过程奖励模型来评价每个输出步骤产生相应的奖励：$R_G = \{\{r_1^{\mathrm{index}(1)}, r_1^{\mathrm{index}(2)}, \cdots, r_1^{\mathrm{index}(K_1)}\}, \{r_2^{\mathrm{index}(1)}, r_2^{\mathrm{index}(2)}, \cdots, r_2^{\mathrm{index}(K_2)}\}, \cdots, \{r_G^{\mathrm{index}(1)}, r_G^{\mathrm{index}(2)}, \cdots, r_G^{\mathrm{index}(K_G)}\}\}$。其中，索引index($j$)是表示第$j$步的终止词元位置，$r_i^{\mathrm{index}(j)}$是通过2.2节中的DRL智能体与环境交互得到的奖励

值反馈获取，K_i为第i个输出序列的总步长。随后，进一步采用均值-标准差归一化方法对这些奖励进行标准化处理，并通过累加后续步骤的归一化奖励来计算$\hat{A}_{i,t}$：

$$\hat{A}_{i,t}=\sum_{\text{index}(j)\geqslant t}\frac{r_i^{\text{index}(j)}-\text{mean}(R_G)}{\text{std}(R_G)} \tag{23}$$

式中：mean(•)和std(•)分别表示求取平均值和方差。

综上所述，GRPO有如下3个重要机制：1）通过G_s个序列的均值进行群体评估，降低了方差；2）引入策略约束剪切机制保障训练稳定性；3）用$\hat{A}_{i,t}$替代传统值函数，减少计算成本。

2.2　基于DRL的第2阶段决策

2.2.1　马尔可夫决策过程建模

在DRL框架下，智能体的决策过程可以建模为一个马尔可夫决策过程（Markov decision process，MDP）。一个MDP可以描述为一个五元数组$(\boldsymbol{S},\boldsymbol{A},\boldsymbol{P},\boldsymbol{R},\gamma)$，其中，状态$s_t\in\boldsymbol{S}$，$\boldsymbol{S}$表示状态空间；动作$a_t\in\boldsymbol{A}$，$\boldsymbol{A}$为动作空间；$\boldsymbol{P}$为状态转移概率函数；$\boldsymbol{R}$为奖励值函数；$\gamma$为折扣因子。

1）状态空间

智能体的观测状态可通过数据采集与监控系统实时获取。基于MDP框架，智能体通过解析观测状态实现策略优化。为适配GCN的图结构特征提取需求，本文构建的观测状态空间包含以下节点特征：节点电压、节点负荷有功功率、节点负荷无功功率和光伏有功出力。智能体在t时刻的观测状态由t时刻各物理量的向量组成，如式（24）所示。

$$s_t=\{\boldsymbol{U}_t,\boldsymbol{P}_t^{\text{load}},\boldsymbol{Q}_t^{\text{load}},\boldsymbol{P}_t^{\text{PV}}\}\in\boldsymbol{S} \tag{24}$$

式中：$\boldsymbol{U}_t$为节点电压向量；$\boldsymbol{P}_t^{\text{load}}$为节点负荷有功功率向量；$\boldsymbol{Q}_t^{\text{load}}$为节点负荷无功功率向量；$\boldsymbol{P}_t^{\text{PV}}$为光伏有功出力向量。

值得说明的是，需要将$\boldsymbol{P}_t^{\text{PV}}$设计为长度为$n_{\text{J}}$的向量。若某节点无光伏电站，则该节点的光伏有功出力置零。

2）动作空间

定义动作空间为式（25）。

$$a_t=\{a_t^{\text{TS}}\}\in\boldsymbol{A} \tag{25}$$

a_t^{TS}代表TS的动作空间，由二元决策变量$\mu_{ij,t}^{\text{TS}}$决定。设配电网中TS的数量为n_{TS}。若不考虑任何约束，a_t的大小为$2^{n_{\text{TS}}}$。显然，动作空间维度随网络规模呈指数级增长，这直接导致“维度灾难”问题。以IEEE 33节点系统为例，该系统包含14个TS，其原始动作空间规模达到2^{14}（16 384）种可能组合，严重制约了算法的实际工程适用性。

传统动作空间缩减方法基于深度优先搜索（depth-first search，DFS）算法[28]，通过式（5）至式（7）所示的辐射状网络约束条件，筛选出满足拓扑要求的可行解空间。文献[29]表明，该方法可将IEEE 33节点系统的动作空间有效缩减至640个可行解。然而，当应用于大规模配电网时，如本文算例采用的20馈线275节点测试系统，该方法仍面临动作空间过于庞大的瓶颈问题。

为此，本文引入基于“开关对”的动作空间优化方法。该方法的核心在于：1）将开关操作限定为成对动作，即一个断开操作与一个闭合操作的组合；2）保留维持现状的操作选项。

尽管该方法理论上可能收敛至局部最优解，但文献[16]论证了“开关对”法并不会牺牲太大的最优性。而“开关对”法具有将动作空间维度降至$O(n^2)$量级的显著优势，适用于大规模系统。基于“开关对”法得到的a_t^{TS}及其空间大小$|a_t^{\text{TS}}|$分别如式（26）、式（27）所示。

$$a_t^{\text{TS}}=\{(i,j)\,|\,i,j\in\Omega_{\text{TS}},i\neq j\}\cup\{(0,0)\} \tag{26}$$

$$|a_t^{\text{TS}}|=n_{\text{TS}}^2-n_{\text{TS}}+1 \tag{27}$$

式（26）定义了开关对(i,j)的操作规则，其中$(0,0)$表示TS保持原状态。式（27）规范了开关动作的编码方式，1表示无操作，$n_{\text{TS}}^2-n_{\text{TS}}$代表从所有TS中任选两个执行一开一关的配对操作。以本文的算例为例，采用“开关对”法可将动作空间规模优化至2 163个可行解，而传统动作空间缩减方法因内存溢出问题无法完成计算任务。显然，“开关对”法减少了动作空间的复杂度，降低了搜索和学习的难度。

需要指出的是，“开关对”法存在一大限制，即无法保证生成的拓扑满足电网运行约束如辐射状运行约束。此外，考虑到动作空间庞大，单纯依靠奖励机制引导智能体选择合法操作的效率过低。因此，需要引入一种掩码机制，通过实时过滤违反电网运行约束的开关操作，动态地调整可行动作空间，保证智能体仅探索合法的解空间。掩码机制的具体实现方法将在2.2.2节详细阐述。

3）状态转移

定义状态转移过程为MDP中的状态转移函数$\boldsymbol{P}$，$s_{t+1}=\boldsymbol{P}(s_t,a_t)$，$\boldsymbol{P}:\boldsymbol{S}\times\boldsymbol{A}\rightarrow\boldsymbol{S}$，表示从状态$s_t$到后续状态$s_{t+1}$的转换过程。其转变可以通过动态改变各节点负荷需求和光伏出力发电来模拟，并通过配电网潮流来进行建模。当0-1变量$\mu_{ij,t}^{\text{TS}}$由智能体代替决策时，原问题被转化为一个可以快速求解的二次约束规划（quadratically constrained programming，QCP）问题。时间尺度方面，本文采

用取 Δt=15 min 的离散化时间步长来执行状态转移，但是重构智能体在小时级进行动作。

4)奖励函数

奖励函数基于式(18)做进一步修正。单步的奖励值求取如式(28)所示。

$$r_t=\sum_{i=1}^{n_J}\left[-c_1(U_{i,t}-1)^2-c_2\sum_{j\in\Omega_n(i)}I_{ij,t}^2r_{ij}\Delta t\right]-c_3\sum_{ij\in\Omega_{TS}}|\mu_{ij,t+1}^{TS}-\mu_{ij,t}^{TS}|-c_4\sum_{i\in\Omega_{Sub}}(P_{i,t}-\bar{P}_t)^2-\mathcal{F}_{end} \tag{28}$$

相较式(18)，奖励函数引入了异常运行惩罚项 $\mathcal{F}_{end}$。对于 $\mathcal{F}_{end}$ 需要做以下说明：1)在完成预设训练周期 T 的迭代更新时，系统自动转入下一训练周期属于正常学习过程，此时不触发惩罚项 $\mathcal{F}_{end}$；2)当 $|U_{i,t}-1|$ 大于 0.1 p.u.，或出现诸如潮流计算不收敛等数值求解失败情况时，奖励函数将加入 $\mathcal{F}_{end}$ 来保证智能体意识到当前操作导致异常工况的严重性。

需要说明的是，结合 2.1 节对 GRPO 技术的讨论，针对每个输入查询 q，由 LLM 生成 G_s 个候选回答，随后 DRL 智能体基于这些回答产生对应的动作选择，最终获得 G_s 组奖励评估值。本文选取其中最大奖励值对应的最优动作执行状态转移。

2.2.2　基于 Gumbel-Softmax 的 SAC 算法

SAC 算法本质来说是一种基于最大熵的 DRL 算法，适用于连续动作空间，通过随机策略优化实现探索与利用的平衡。从网络架构角度分析，SAC 算法采用五网络并行计算结构。具体包括 1 个 actor 网络，2 个价值(critic)网络和 2 个目标价值(target-critic)网络。以 ϕ 参数化 actor 网络。以 $\varphi_w, w\in\{1,2\}$ 参数化 2 个 critic 网络。2 个 target-critic 网络分别对应 2 个 critic 网络，以 $\underline{\varphi}_w, w\in\{1,2\}$ 参数化 target-critic 网络[30]。

SAC 算法的目标之一是找到智能体最优策略，并最大化策略的熵 $J(\pi)$：

$$\max_{\pi}J(\pi)=\sum_{t=1}^{T}E_{s,a\sim\rho_\pi}[R_t+\alpha H(\pi(s_t))] \tag{29}$$

式中：a 为智能体的动作；R_t 为 t 时刻智能体的累计折扣奖励；α 为有关熵的权重参数；ρ_π 为智能体策略 π 的轨迹；$H(\pi(s_t))=-E_{s,a\sim\rho_\pi}\log\pi$ 为策略 π 的熵的期望值。

根据式(26)的数学表述，配电网重构智能体的动作空间本质上是离散的。这一特性导致传统基于连续动作空间的 SAC 算法面临两个关键挑战：1)离散动作不可微分性阻碍了梯度反向传播；2)传统的高斯分布无法直接建模离散策略。为解决上述问题，本文引入 Gumbel-Softmax 重参数化技术。其核心机理在于软化概率分布，将离散分布近似表示为连续概率分布[16]。Gumbel-Softmax 技术允许动作 a_t 为离散动作，且使得 actor 网络可以从离散动作空间提取有效梯度信号，获得近似的优化梯度并改善策略 π_ϕ：

$$\hat{\pi}_\phi(s_t)=\mathrm{Softmax}\left(\frac{f_\phi(s_t)+G_n}{\tau_{te}}+\mathrm{flat}(\log\chi_t)\right) \tag{30}$$

$$G_n=-\log(-\log u),\ u\sim\mathrm{Uniform}(0,1) \tag{31}$$

式中：G_n 为遵循 Gumbel 分布的噪声；Uniform(0,1)表示在区间[0,1]上的连续均匀分布；τ_{te} 为温度系数；f_ϕ 被 ϕ 参数化，输出未归一化的对数概率；$\hat{\pi}_\phi(s_t)$ 为基于 Gumbel-Softmax 的采样策略；χ_t 为用于过滤不合法动作的二进制矩阵；flat(·)在本文中特指按行优先顺序将矩阵展平为一维数组，并在该一维数组中去除原矩阵中除第 1 个对角线元素外的其他对角线元素。在本文中，χ_t 的大小为 $n_{TS}\times n_{TS}$。对于 χ_t 中的元素 $\chi_t(i,j)$，若 $\chi_t(i,j)$ 为 0，则 $\log\chi_t(i,j)$ 生成一个极负值，迫使其通过 Softmax 运算得到的动作概率接近于 0，进而过滤不合法动作。矩阵 χ_t 可以通过附录 A 算法 A1 获得。

Gumbel-Softmax 具有较低方差的梯度可以近似由式(32)、式(33)求取。

$$z=\mathrm{onehot}(\mathrm{argmax}(\hat{\pi}_\phi(s))) \tag{32}$$

$$\hat{a}_t=z-\mathrm{const}(\hat{\pi}_\phi(s))+\hat{\pi}_\phi(s) \tag{33}$$

式中：argmax(·)用于返回具有最大概率的动作；const(·)用于切断梯度传播；onehot(·)用于将动作编码为 one-hot 向量，其中，只有所选动作才置 1，其余均置为 0；$\hat{a}_t$ 为 a_t 的近似值。

通过最小化状态动作函数的 Softmax 分布和策略 π 之间的 KL 散度，可以计算得到 actor 网络的策略梯度以及用于更新的目标函数，有

$$J_\pi(\phi)=E_{s,a\sim\rho_\pi}\alpha H(\pi(s_t))-\min_{w\in\{1,2\}}Q_{\varphi_w}(s_t,\hat{a}_t) \tag{34}$$

式中：$Q_{\varphi_w}(\cdot)$ 为动作价值函数。

critic 网络的迭代更新如式(35)、式(36)所示。

$$\nabla_{\varphi_w}J(\varphi_w)=\nabla_{\varphi_w}\|y_t-Q_{\varphi_w}(s_t,\hat{a}_t)\|^2 \tag{35}$$

$$y_t=r_t+\gamma\min_{w=1,2}(Q_{\underline{\varphi}_w}(s_{t+1},\hat{a}_{t+1}))+\alpha^TH(\hat{\pi}_\phi) \tag{36}$$

SAC 借助双重价值函数估计机制，通过最小化两套独立参数化 critic 网络的输出实现了目标值裁剪。

target-critic 网络的网络参数更新，如式(37)所示。

$$\underline{\varphi}_w=\delta\varphi_w+(1-\delta)\underline{\varphi}_w \tag{37}$$

式中：δ为软更新参数。target-critic网络参数通过自身和critic网络的网络参数加权相加进行更新，以促进SAC算法的稳定计算更新。

2.2.3　GCN的嵌入

配电网本质上是一个具有明确图结构的物理系统。与非欧几何拓扑类似，具有n_{B}根馈线的配电网可以视为由n_{J}个节点和$n_{\mathrm{J}}-n_{\mathrm{B}}$条边组成的无向图，记为$G=(O,E)$，其中，$O$和$E$分别代表无向图节点和边的集合。传统卷积神经网络难以直接处理此类非欧几里得空间数据，而GCN通过谱域卷积或空间域消息传递机制[31]，能够更显式建模。

G可以由两个矩阵进行表示，分别是节点特征矩阵$\boldsymbol{Y}$和邻接矩阵$\boldsymbol{\mu}$。$\boldsymbol{Y}$和$\boldsymbol{\mu}$被作为GCN的输入数据，在多层GCN中的传播遵循以下原则：

$$\boldsymbol{\eta}_{(n\times N)}^{(0)}=\boldsymbol{Y}_{(n\times N)}^{(0)} \tag{38}$$

$$\boldsymbol{\eta}_{(y\times N)}^{(l+1)}=\sigma\left(\hat{\boldsymbol{D}}_{(N\times N)}^{-\frac{1}{2}}\hat{\boldsymbol{\mu}}_{(N\times N)}\hat{\boldsymbol{D}}_{(N\times N)}^{-\frac{1}{2}}\hat{\boldsymbol{\eta}}_{(x\times N)}^{(l)}\hat{\boldsymbol{W}}_{\mathrm{G}}^{(l)}\right) \tag{39}$$

式中：x为输入节点索引；y为输出节点索引；n为节点特征的原始维度；$\hat{\boldsymbol{\eta}}_{(x\times N)}^{(l)}$表示第$l$层输出的新图特征；$\boldsymbol{Y}_{(n\times N)}^{(0)}$为配电网拓扑图的原始特征矩阵；$\hat{\boldsymbol{\mu}}_{(N\times N)}$为考虑单位元素的邻接矩阵；$\hat{\boldsymbol{D}}$为对角节点度矩阵；$\hat{\boldsymbol{W}}_{\mathrm{G}}^{(l)}$为第$l$层的可训练图矩阵，本质上决定了连接节点之间的边权重；σ为激活函数。

对于图G，其拉普拉斯矩阵被定义为$\hat{\boldsymbol{L}}=\hat{\boldsymbol{D}}-\hat{\boldsymbol{\mu}}$。可以推导得到$\hat{\boldsymbol{L}}$是一个半正定矩阵且为实对称矩阵。因此，$\hat{\boldsymbol{L}}$可对角化为：

$$\hat{\boldsymbol{L}}=\boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{\mathrm{T}}=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \cdots & \boldsymbol{v}_n\end{bmatrix}\begin{bmatrix}\lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n\end{bmatrix}\begin{bmatrix}\boldsymbol{v}_1^{\mathrm{T}}\\ \boldsymbol{v}_2^{\mathrm{T}}\\ \vdots\\ \boldsymbol{v}_n^{\mathrm{T}}\end{bmatrix} \tag{40}$$

式中：$\boldsymbol{V}$为$\hat{\boldsymbol{L}}$的正交矩阵；$\boldsymbol{\Lambda}$为对应特征值组成的对角矩阵。

在实际工况中，GCN首先将空间图信号变换到频域，然后利用频率响应矩阵对变换后的信号进行滤波，最后将信号变换回空间域，实现图信号的特征提取，如式(41)、式(42)所示。

$$\boldsymbol{Y}=\boldsymbol{V}\boldsymbol{\Lambda}_{\mathrm{h}}\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x} \tag{41}$$

$$\boldsymbol{\Lambda}_{\mathrm{h}}=\begin{bmatrix}h_{\mathrm{f}}(\lambda_1) & & & \\ & h_{\mathrm{f}}(\lambda_2) & & \\ & & \ddots & \\ & & & h_{\mathrm{f}}(\lambda_n)\end{bmatrix} \tag{42}$$

式中：$\boldsymbol{\Lambda}_{\mathrm{h}}$为频率响应矩阵；$h_{\mathrm{f}}(\cdot)$为频率响应函数；$\boldsymbol{Y}$和$\boldsymbol{x}$分别为输出和输入。

记$\hat{\boldsymbol{D}}^{-\frac{1}{2}}\hat{\boldsymbol{\mu}}\hat{\boldsymbol{D}}^{-\frac{1}{2}}$为$F_{\mathrm{GCN}}$，有

$$\begin{aligned}F_{\mathrm{GCN}}&=\hat{\boldsymbol{D}}^{-\frac{1}{2}}\hat{\boldsymbol{\mu}}\hat{\boldsymbol{D}}^{-\frac{1}{2}}=\hat{\boldsymbol{D}}^{-\frac{1}{2}}(\hat{\boldsymbol{D}}-\hat{\boldsymbol{L}})\hat{\boldsymbol{D}}^{-\frac{1}{2}}=\\&\boldsymbol{I}-\hat{\boldsymbol{D}}^{-\frac{1}{2}}\hat{\boldsymbol{L}}\hat{\boldsymbol{D}}^{-\frac{1}{2}}=\boldsymbol{I}-\tilde{\boldsymbol{L}}_{\mathrm{s}}=\\&\boldsymbol{I}-\boldsymbol{V}_{\mathrm{G}}\tilde{\boldsymbol{\Lambda}}\boldsymbol{V}_{\mathrm{G}}^{\mathrm{T}}=\boldsymbol{V}_{\mathrm{G}}(\boldsymbol{I}-\tilde{\boldsymbol{\Lambda}})\boldsymbol{V}_{\mathrm{G}}^{\mathrm{T}}\end{aligned} \tag{43}$$

式中：$\tilde{\boldsymbol{L}}_{\mathrm{s}}$为归一化拉普拉斯矩阵；$\boldsymbol{V}_{\mathrm{G}}$为$\tilde{\boldsymbol{L}}_{\mathrm{s}}$的特征向量；$\tilde{\boldsymbol{\Lambda}}$为频率响应矩阵；$\boldsymbol{I}-\tilde{\boldsymbol{\Lambda}}$构成滤波器。

本文令GCN和全连接层一同构成了actor、critic和target-critic网络，并实现同步更新。GCN在前向传播中保留梯度信息，故在反向传播阶段，其参数可与后续网络一同通过梯度下降进行优化。利用GCN对邻域节点特征进行深度挖掘与动态聚合，有效捕捉了复杂拓扑结构中的高阶关联性。

2.3　两阶段联合求解算法流程

本文所提的一种融合LLM和DRL智能体的两阶段决策算法流程如附录A算法A2所述。

3　算例分析

为验证本文所提两阶段联合决策优化算法的有效性和优越性，选取某实际配电网系统进行测试验证。该测试系统拓扑结构如附录B图B1所示，包含20个馈线根节点、275个节点以及268条支路，其中47条支路配备TS，其余为固定支路。系统基准容量为10 MW，基准电压为10 kV，根节点电压固定为1.01 p.u.。系统中共20个节点接入光伏发电单元，其容量配置详见表B1。图B2展示了一个典型运行周期内系统总负荷需求与光伏发电出力的时序变化曲线。

本算例设置一个LLM和一个智能体来管控该10 kV电压等级配电系统。LLM由DeepSeek-R1-Distill-Qwen-7B模型微调得到。而DRL算法中，评估网络包括1个输入层、2个隐藏层、1个输出层，隐藏层之间采用ReLU作为激活函数。DRL算法基于Python 3.9的Pytorch框架，算例的仿真环境为Intel(R) Xeon(R) Platinum 8473C，8张NVIDIA GeForce RTX 4090。网络结构及相关超参数设定如附录B表B2所示。系统prompt和用户prompt设计如附录C所示。

3.1　收敛性分析

本节首先通过分析式(22)中的$J_G(\theta)$来验证LLM训练的收敛情况，如附录B图B3所示，共统计了600个回合的数据。结合式(22)、式(23)和图B3，在训练初期也就是探索阶段，策略概率比R_{pp}的随机波动使得$J_G(\theta)$的值在正负区间波动，其正负性由$\hat{A}_{i,t}$与策略更新的局部一致性决定(若$\hat{A}_{i,t}$为

正，则$J_G(\theta)$也为正，表明$\hat{A}_{i,t}$对$J_G(\theta)$有正的贡献度）。在训练中期也就是优化期，策略梯度逐步倾向于提升高优势样本（$\hat{A}_{i,t}$为正）的概率，$J_G(\theta)$以正值为主，这一阶段策略持续优化改进。在训练后期也就是收敛阶段，策略优化收益减小，$J_G(\theta)$收敛至微正值区间，这一阶段$J_G(\theta)$波动性减弱，方差降低，策略趋向于确定化。

附录B图B4进一步展示了LLM的输出特性。图B4统计了每200个回合LLM生成的各馈线次数。在训练初期，LLM处于探索阶段，对各馈线的探索频次呈现均匀分布特征，随着训练进行至中后期，输出分布显著收敛，LLM的输出集中分布于馈线10和馈线11（馈线10为主），其余馈线的选择概率降至可忽略水平，LLM的输出逐渐稳定。这一现象论证了LLM训练逐渐收敛，同时表明馈线10的节点拓扑或负荷特性使其成为本算例的重构关键，需优先保供。此外，可以发现，前中后期3个阶段LLM认定需要进行转供的馈线总数逐渐减少。这是因为随着训练的深入，LLM逐步学习到最优负荷转供模式，在训练中后期对关键馈线（如馈线10）的辨识准确率提升，减少了冗余操作（本文中若LLM认定无须强制对某馈线进行转供，令LLM输出空集以终止操作，减少不必要的干预）。

SAC算法是一种收敛性能强的离线策略算法，而PPO算法是一种计算复杂度低的在线策略算法。本节进一步对比GCN+SAC算法（简称GSAC）、GCN+PPO算法（简称GPPO）、SAC算法和本文所提LLM-GSAC算法的收敛性能，以论证LLM-GSAC引入LLM进行先验引导的优势。各算法训练阶段的奖励曲线如图3所示。

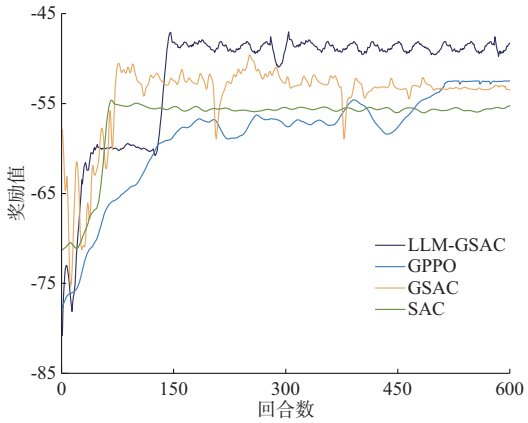


图3　不同算法的奖励收敛曲线

Fig. 3　Reward convergence curves for various algorithms

由图3的收敛曲线可知，GSAC算法在SAC算法的基础上引入GCN，加强了智能体对大规模动态拓扑变化的感知能力。虽然SAC算法仅需约70个训练回合即可收敛，但其较早地陷入了局部最优，算法控制性能欠佳。同理，嵌入GCN的GPPO算法尽管收敛速度慢、训练波动大，但由于GCN通过节点特征聚合机制有效捕捉了邻域耦合关系，最后呈现的算法最优性亦优于SAC算法。

本文提出的LLM-GSAC算法在GSAC基础上融合了LLM进行一阶段决策引导。本文所提方法历经约150个回合实现收敛，这是因为LLM的策略微调增加了模型复杂度，但其通过语义理解实现的馈线转供意图识别为DRL智能体提供了明确的决策方向。因此，DRL智能体可以更精准地指导配电网重构，最优化性能增强。

3.2　配电网重构效果

为验证本文所提配电网重构框架在实现控制目标方面的有效性，本节对馈线负荷平衡性、电压偏差和网损3个配电网关键控制指标进行分析。

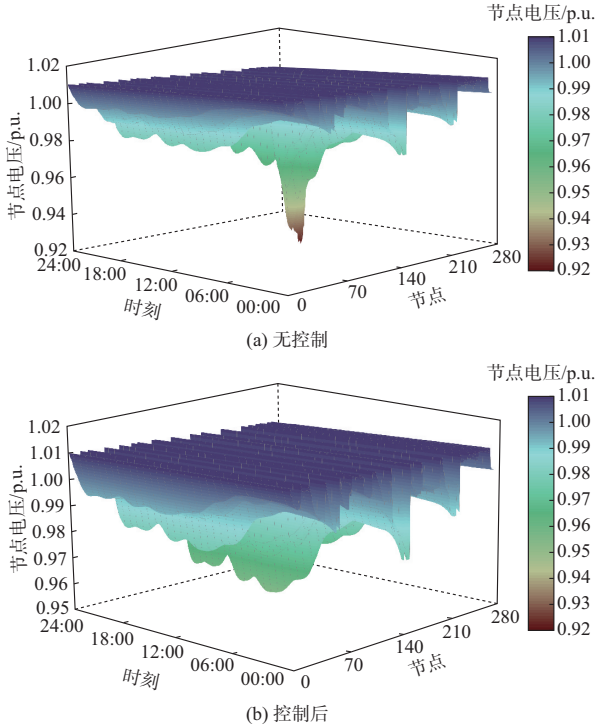
对本文所提算法进行测试，重构前后支路状态如附录B图B5所示，其中，1表示支路闭合，0表示支路打开。智能体给出的重构方案具体如下：在10:00前先后断开支路（116,126）闭合支路（126,206），断开支路（147,148）闭合支路（152,160），断开支路（91,93）闭合支路（94,30），断开支路（35,36），闭合支路（10,37）。随后，配电网拓扑保持不变。

负荷不平衡会导致部分馈线重过载，而其他馈线处于轻载状态，造成资源浪费。附录B图B6展示了配电网重构前后20条馈线负荷不平衡度的变化，度量这一不平衡度的计算方法参照式（18）。由图B6(a)可知，重构前馈线14在负荷高峰期11:00至18:00出现了较为明显的负荷不平衡，而在重构后馈线14的负荷不平衡度下降了约34%，馈线14的负荷平衡度有效提高。对比图B6(a)与图B6(b)表明重构后负载分布更为均衡，验证了所提算法在负载保供优化方面的有效性。

结合附录B图B5分析重构智能体缓解馈线不平衡的具体机制。通过断开（91,93）闭合（94,30）、断开（35,36）闭合（37,10），原来由馈线14进行供电的93-101被转由馈线18进行供电。馈线18因新增负荷而出现过载，节点36～38被进一步转移到保供压力并不大的馈线20。这种连续的负荷转移表明，本文所提方法可以实现馈线间的动态负载均衡。

为分析配电网重构前后的电压控制效果，本节针对全网和典型节点分析了电压越限的改善效果。如图4(a)所示，控制前12:00节点140至152均出现了较为严重的电压跌落问题，最低电压为0.921 p.u.。

对比图4(b)与图4(a)，控制后所有节点的电压均控制在0.954～1.010 p.u.，图4(b)中均为青蓝色，并未出现图4(a)中的棕色。



(a) 无控制

(b) 控制后

图4　电压控制前后节点电压对比

Fig. 4　Comparison of node voltage before and after voltage control

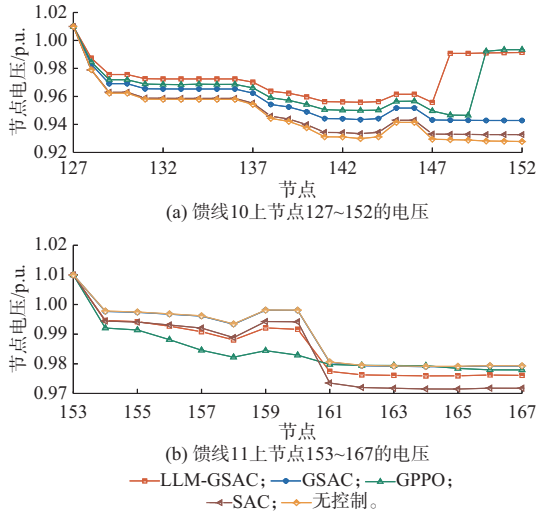
结合附录B图B5分析重构智能体减小电压偏差的具体机制。通过断开支路(147，148)闭合支路(152，160)，将节点148～152接到节点160转由节点153即馈线10进行供电(原来由节点127即馈线11进行供电)，避免了节点148～152的电压越限，进而也缓解了节点140～147的电压越限状况。如图B7所示，选取典型节点147与152进一步分析。随着节点148～152被转供至其他馈线，原来的馈线末端节点152的电压越限得到了显著的改善。而节点148～152的上游节点147的电压跌落问题也随着下游负荷的转移自然得到了解决。上述的电压控制效果表明了本文所提重构方法的有效性和其在多馈线间协同电压调节的优势。

进一步分析配电网重构前后的网损控制效果，结果如附录B图B8所示。从图B8可以观察到，在实施控制策略后，配电网在几乎所有时段的网损较控制前均得到改善。根据IEEE Std 1547—2018技术规范[32]，负荷平衡和电压稳定性是影响配电网损耗的两个独立关键因素。通过前文分析可知，本算例中馈线负载不平衡度的优化使得电力负荷分布趋于均衡；同时，节点电压偏差的降低有效提升了系统电压稳定性，从而减少了电压波动引起的非必要电流流动。这些因素协同作用最终导致配电网网损的降低，该理论分析结论与仿真结果具有良好的一致性。

3.3　不同算法对比

为验证本文所提LLM-GSAC算法在配电网重构控制效果方面的优越性，将其与GSAC、GPPO、SAC算法进行对比分析。

图5展示了13:00用电高峰时馈线10和11的电压分布情况。



(a) 馈线10上节点127~152的电压

(b) 馈线11上节点153~167的电压

图5　不同算法下典型馈线电压分布

Fig. 5　Voltage distribution along typical feeders under various algorithms

根据前文分析，重构前由于负荷节点数量庞大且处于需求峰值，馈线10承受着显著的供电压力，多个节点电压跌落至0.93 p.u.以下。配电网重构后，重过载的末端节点转供至负载率较低的馈线11，馈线10的电压跌落问题得到改善。而馈线11并没有因为新节点负荷的接入出现电压跌落的现象，相反，馈线11上的节点电压均维持在0.97 p.u.以上，保持较高的电能质量。相较于GSAC和GPPO算法，本文所提算法对于馈线10电压分布的优化效果更为明显。SAC算法由于过早陷入局部最优，算法控制性能欠佳，电压跌落略有改善。这一结果表明，通过微调LLM进行一阶段决策给出馈线组，能引导智能体更准确地捕捉待转供馈线和待保供节点，显著提升了重构策略的控制精度和效果。

最后，表1展示了一个周期内不同算法在4个优化指标(如式(18)所示)、综合目标函数和测试集计算时间上的性能表现，其中，优化指标均以标幺值的形式给出。本文所提LLM-GSAC算法通过微调LLM进行一阶段输出，有效促进了DRL智能体二

阶段的学习和优化。与无控制场景相比，LLM-GSAC算法在将节点电压稳定控制在[0.95,1.05] p.u.范围内的同时，实现了网损降低和馈线负载平衡度的优化。相较于GSAC、GPPO和SAC算法，LLM-GSAC算法在4个优化指标上均更优，表明了LLM-GSAC算法更强的全局感知、统筹和评估能力，避免陷入单一指标优化的局部最优困境。此外，本文所提方法与其他强化学习方法在测试集计算时间上相当，均可实现秒级实时转供，工程应用上可完全满足实时重构的实时性需求。

表1　不同算法的各指标优化结果

Table 1　Optimization results of different metrics for various algorithms

算法	电压/p.u.			网损/p.u.	负载平衡指标	动作成本	总目标函数	测试集计算时间/s
	电压偏差	最小电压	最大电压					
LLM-GSAC	57.576	0.954	1.010	11.316	115.008	1.00	48.628	45.65
GSAC	60.004	0.940	1.010	11.716	120.928	0.50	53.004	16.42
GPPO	57.812	0.947	1.010	11.432	121.588	1.00	52.529	11.17
SAC	68.064	0.9296	1.010	11.712	129.624	0.75	55.445	12.84
无控制	86.452	0.921	1.010	11.664	136.160	0	62.012	

4　结语

本文提出了基于LLM和DRL智能体两阶段联合决策的配电网重构方法。

1)提出一种两阶段优化框架：在第1阶段微调LLM进行训练，使其能够准确输出待转供的候选馈线编号集合，从而提升第2阶段DRL的探索效率和学习效果。

2)针对DRL动作空间维数灾问题，结合“开关对”动态优化方法与掩码机制，将动作空间维度降至$O(n^2)$的量级。

3)对SAC算法进行改进，引入Gumbel-Softmax重参数化技术，使其适用于离散动作空间。同时，嵌入GCN加强智能体对大规模动态拓扑变化的感知能力。

算例表明了本文所提重构方法在减小馈线负荷不平衡度、电压偏差和网损方面的优势。然而，本文每个时间步仅支持单次开关对动作操作，这与实际配电网重构应用中常见的多开关协同操作需求存在差距。后续研究将开发基于时序决策树的开关动作序列优化算法，并引入动作优先级评估机制，确保多开关操作的安全性与最优性。

本文在审稿过程中部分审稿专家意见和作者回复见附录D。

附录见本刊网络版，点击http://www.aeps-info.com/aeps/article/abstract/20250411004，或扫描英文摘要后二维码，可阅读全文。

参考文献

[1] 阮广春，何一鎏，谭振飞，等.面向新型电力系统运行的数据-物理融合建模综述[J].中国电机工程学报，2024，44(13)：5021-5037.
RUAN Guangchun, HE Yiliu, TAN Zhenfei, et al. Review of hybrid data-driven and physics-based modeling for the operation of new-type power systems[J]. Proceedings of the CSEE, 2024, 44(13): 5021-5037.

[2] GAO H J, JIANG S Y, LI Z M, et al. A two-stage multi-agent deep reinforcement learning method for urban distribution network reconfiguration considering switch contribution [J]. IEEE Transactions on Power Systems, 2024, 39(6): 7064-7076.

[3] ABBAS G, WU Z, ALI A. Multi-objective multi-period optimal site and size of distributed generation along with network reconfiguration[J]. IET Renewable Power Generation, 2024, 18(16): 3704-3730.

[4] 张晓，吴志，郑舒，等.基于贝叶斯深度强化学习的主动配电网电压控制[J].电力系统自动化，2024，48(20)：81-90.
ZHANG Xiao, WU Zhi, ZHENG Shu, et al. Voltage control for active distribution network based on Bayesian deep reinforcement learning[J]. Automation of Electric Power Systems, 2024, 48(20): 81-90.

[5] 彭佳盛，文云峰，梁晓锐，等.基于弹性系数的配电网重构与故障抢修协同优化方法[J].电力系统自动化，2025，49(6)：88-95.
PENG Jiasheng, WEN Yunfeng, LIANG Xiaorui, et al. Collaborative optimization method of distribution network reconfiguration and fault repair based on elastic coefficient[J]. Automation of Electric Power Systems, 2025, 49(6): 88-95.

[6] 张泽坤，杨洁，刘念.计及拓扑相似性的含分散式风电配网双层优化重构方法[J].电网技术，2024，48(6)：2436-2447.
ZHANG Zekun, YANG Jie, LIU Nian. A bi-level topology similarity-based optimal reconfiguration method for distribution network with distributed wind power [J]. Power System Technology, 2024, 48(6): 2436-2447.

[7] BEHBAHANI M R, JALILIAN A, BAHMANYAR A, et al. Comprehensive review on static and dynamic distribution network reconfiguration methodologies [J]. IEEE Access, 2024, 12: 9510-9525.

[8] 潘凯岩，刘宏达，刘延乐.基于重构级别辨识的主配协同鲁棒供

电恢复方法[J].电力系统自动化，2025，49(2)：175-185.
PAN Kaiyan, LIU Hongda, LIU Yanle. Robust power supply restoration method with coordination of main grid and distribution networks based on reconstruction level identification [J]. Automation of Electric Power Systems, 2025, 49(2): 175-185.

[9] 徐小琴，王博，赵红生，等.基于布谷鸟搜索和模拟退火算法的两电压等级配网重构方法[J].电力系统保护与控制，2020，48(11)：84-91.
XU Xiaoqin, WANG Bo, ZHAO Hongsheng, et al. Reconfiguration of two-voltage distribution network based on cuckoo search and simulated annealing algorithm [J]. Power System Protection and Control, 2020, 48(11): 84-91.

[10] 于艾清，丁丽青，王育飞，等.基于单环寻优策略的有源配网重构方法[J].电力系统保护与控制，2022，50(1)：23-32.
YU Aiqing, DING Liqing, WANG Yufei, et al. Active distribution network reconfiguration based on single loop optimization strategy [J]. Power System Protection and Control, 2022, 50(1): 23-32.

[11] LI J K, GE S Y, LIU H, et al. Domestic P2P energy market design considering network reconfiguration and usage fees: bi-level nonlinear programming and exact clearing algorithm [J]. Applied Energy, 2024, 368: 123039.

[12] 张玉敏，杨子震，叶平峰，等.市场环境下考虑配网重构和需求响应的输配协同优化调度[J].高电压技术，2025，51(6)：2954-2964.
ZHANG Yumin, YANG Zizhen, YE Pingfeng, et al. Collaborative optimization scheduling of transmission and distribution considering distribution network reconfiguration and demand response in market environment [J]. High Voltage Engineering, 2025, 51(6): 2954-2964.

[13] HELMI A M, CARLI R, DOTOLI M, et al. Efficient and sustainable reconfiguration of distribution networks via metaheuristic optimization [J]. IEEE Transactions on Automation Science and Engineering, 2022, 19(1): 82-98.

[14] GAO Y Q, WANG W, SHI J, et al. Batch-constrained reinforcement learning for dynamic distribution network reconfiguration[J]. IEEE Transactions on Smart Grid, 2020, 11(6): 5357-5369.

[15] WANG C, LEI S B, JU P, et al. MDP-based distribution network reconfiguration with renewable distributed generation: approximate dynamic programming approach [J]. IEEE Transactions on Smart Grid, 2020, 11(4): 3620-3631.

[16] WANG R H, BI X W, BU S Q. Real-time coordination of dynamic network reconfiguration and Volt-VAR control in active distribution network: a graph-aware deep reinforcement learning approach [J]. IEEE Transactions on Smart Grid, 2024, 15(3): 3288-3302.

[17] WU T, WANG J H, LU X N, et al. AC/DC hybrid distribution network reconfiguration with microgrid formation using multi-agent soft actor-critic [J]. Applied Energy, 2022, 307: 118189.

[18] LI Y Z, HAO G K, LIU Y, et al. Many-objective distribution network reconfiguration via deep reinforcement learning assisted optimization algorithm [J]. IEEE Transactions on Power Delivery, 2022, 37(3): 2230-2244.

[19] 孙秋野，张瑞霞，陈东岳.大模型技术赋能电力系统的应用及技术路线展望[J/OL].电力系统自动化：1-22[2025-04-11]. https://kns.cnki.net/kcms/detail/32.1180.TP.20250317.1811.006.html.
SUN Qiuye, ZHANG Ruixia, CHEN Dongyue. Application and technical route prospect of large model technology to empower power system[J/OL]. Automation of Electric Power Systems: 1-22[2025-04-11]. https://kns.cnki.net/kcms/detail/32.1180.TP.20250317.1811.006.html.

[20] 余建明，刘赫，单连飞，等.基于ALBERT和RE2融合模型的电网调度意图识别方法[J].电力系统保护与控制，2022，50(12)：144-151.
YU Jianming, LIU He, SHAN Lianfei, et al. Method of power grid dispatch intention recognition based on ALBERT and RE2 fusion model[J]. Power System Protection and Control, 2022, 50(12): 144-151.

[21] HAN B W, LI H F, WANG G, et al. A virtual multi-terminal current differential protection scheme for distribution networks with inverter-interfaced distributed generators [J]. IEEE Transactions on Smart Grid, 2018, 9(5): 5418-5431.

[22] 丁涛，杨岳洋，汪顺其，等.配电网拓扑重构下辐射状约束建模综述[J/OL].电网技术：1-20[2025-03-28].https://doi.org/10.13335/j.1000-3673.pst.2024.2167.
DING Tao, YANG Yueyang, WANG Shunqi, et al. A review of radiality constraint modeling in distribution network reconfiguration[J/OL]. Power System Technology: 1-20[2025-03-28]. https://doi.org/10.13335/j.1000-3673.pst.2024.2167.

[23] 刘一兵，吴文传，张伯明，等.基于混合整数二阶锥规划的主动配电网有功-无功协调多时段优化运行[J].中国电机工程学报，2014，34(16)：2575-2583.
LIU Yibing, WU Wenchuan, ZHANG Boming, et al. A mixed integer second-order cone programming based active and reactive power coordinated multi-period optimization for active distribution network[J]. Proceedings of the CSEE, 2014, 34(16): 2575-2583.

[24] DING T, HU Y, BIE Z H. Multi-stage stochastic programming with nonanticipativity constraints for expansion of combined power and natural gas systems [J]. IEEE Transactions on Power Systems, 2018, 33(1): 317-328.

[25] EHSAN A, YANG Q. Optimal integration and planning of renewable distributed generation in the power distribution networks: a review of analytical techniques [J]. Applied Energy, 2018, 210: 44-59.

[26] LI Y X, YU Y F, LIANG C, et al. LoftQ: LoRA-fine-tuning-aware quantization for large language models[EB/OL]. (2023-10-16)[2025-04-11]. https://arxiv.org/abs/2310.08659.

[27] SHAO Z, WANG P, ZHU Q, et al. DeepSeekmath: pushing the limits of mathematical reasoning in open language models [EB/OL]. (2024-02-03)[2025-04-11]. https://arxiv.org/abs/2402.03300.

[28] 刘航，李玉龙，王波，等.基于深度优先搜索的电力系统安全风险诊断方法[J].电工技术，2023(14)：180-182.
LIU Hang, LI Yulong, WANG Bo, et al. Power system security diagnosis method based on depth first search [J]. Electrical Engineering Technology, 2023(14): 180-182.

[29] WANG B B, ZHU H, XU H H, et al. Distribution network reconfiguration based on NoisyNet deep Q-learning network[J]. IEEE Access, 2021, 9: 90358-90365.
[30] HAARNOJA T, ZHOU A, HARTIKAINEN K, et al. Soft actor-critic algorithms and applications[EB/OL]. (2018-12-12)[2025-04-11]. https://arxiv.org/abs/1812.05905.
[31] KIPF T, WELLING M. Semi-supervised classification with graph convolutional networks[EB/OL]. (2016-09-30)[2025-04-11]. https://arxiv.org/abs/1609.02907.
[32] IEEE standard for interconnection and interoperability of distributed energy resources with associated electric power systems interfaces: IEEE Std 1547—2018[S]. 2018.

周茂一(2003—),男,硕士研究生,主要研究方向:人工智能在配电网中的应用。E-mail:470919009@qq.com
吴　志(1987—),男,通信作者,博士,副教授,主要研究方向:输电网及配电网运行与规划、分布式发电、电力市场。E-mail:zwu@seu.edu.cn
张　晓(2000—),女,博士研究生,主要研究方向:配电网电压控制、配电网重构。E-mail:220232913@seu.edu.cn

(编辑　代长振)

A Distribution Network Reconfiguration Method Based on Joint Decision-making of Large Language Models and Deep Reinforcement Learning

ZHOU Maoyi[1], *WU Zhi*[1], *ZHANG Xiao*[1], *BU Dongdong*[2], *SUN Zhendong*[2], *ZHAO Ruifeng*[3]
(1. School of Electrical Engineering, Southeast University, Nanjing 210096, China;
2. Shenzhen Power Supply Bureau Co., Ltd., Shenzhen 518001, China;
3. Guangzhou Power Supply Bureau of Guangdong Power Grid Co., Ltd., Guangzhou 510623, China)

Abstract: To address the challenges of secure distribution network operation and reliable load supply under high-penetration renewable energy integration, this paper proposes a distribution network reconfiguration method based on joint decision-making of large language model (LLM) and deep reinforcement learning (DRL) agents. First, a multi-objective dynamic distribution network reconfiguration model is formulated, and a two-stage joint decision-making framework is designed. In the first stage, a fine-tuned LLM identifies dispatching instruction intentions and preliminarily screens the range of transfer feeders. This assists the exploration and learning of the DRL agent. In the second stage, an improved soft actor-critic (SAC) algorithm is employed. The Gumbel-Softmax reparameterization technique enables the policy network to extract valid gradient signals from the discrete action space. Meanwhile, a graph convolutional network (GCN) is embedded to enhance topological feature extraction and topology variation perception. To reduce the action space size, the "switch pair" method and action space masking mechanism are introduced. This ensures the validity of all operations. Finally, case studies on a practical distribution system verify the effectiveness and superiority of the proposed method.

This work is supported by Smart Grid-National Science and Technology Major Project (No. 2024ZD0802200).

Key words: distribution network reconfiguration; large language model (LLM); deep reinforcement learning; agent; soft actor-critic (SAC) algorithm; graph convolutional network (GCN); joint decision-making